Analyse Statistique et Description : Jeu de Données "GeneX"

MATAOUI Haron et HALIMI Akram – Binôme N° 1

Ce projet exploite deux sources de données complémentaires issues du *Cancer Genome Atlas* (TCGA) pour prédire le statut vital de patients atteints de cancer. La première source (Dataset **GeneX**) contient les profils d'expression de 5000 gènes, illustrant l'approche de la génomique. La seconde (Dataset **Clinical**) regroupe 24 variables cliniques et démographiques, représentant l'approche médicale classique. L'objectif est de comparer ces deux approches et, potentiellement, de les combiner pour améliorer la prédiction pronostique.

Dataset 1 : GeneX (Données Génomiques)

1. Présentation des Données

Ce projet s'intéresse au jeu de données "Gene" pour traiter un **problème de classification**. L'objectif est de prédire le statut vital des patients (représenté par la variable cible Y : "Alive" vs "Dead") en se basant sur leurs profils d'expression génétique (X).

- **Dimensions ($p \gg n$) :** Le tableau comporte $p = 5000$ variables (gènes) pour seulement 1231 patients. Ce ratio élevé constitue le défi statistique central de ce projet.
- **Nature des Valeurs :** Les données sont numériques et continues. L'inspection de la distribution des valeurs (allant de 0 à environ 20) et leur forme quasi-gaussienne indiquent qu'elles correspondent à des niveaux d'expression normalisés, probablement transformés en log.
- **Intégrité :** les données ne présentent aucune valeurs manquantes (`NA`) et de gènes à variance nulle, le rendant prêt pour l'analyse.

2. Nature du Problème

La haute dimensionnalité et l'hétérogénéité moléculaire soulignées par le ***Cancer Genome Atlas Network*** (2012) rendent la régression standard inopérante (colinéarité, sur-apprentissage). L'approche pénalisée (Lasso, Elastic-Net) est donc impérative pour extraire les biomarqueurs du bruit.

3. Variables Explicatives (X)

Le tableau `GeneX` contient les niveaux d'expression de 5000 gènes. Nous avons exploré la structure globale des données via une Heatmap des gènes les plus variants.

- **Structure (Fig. 1) :** Le mélange des classes dans la barre d'annotation supérieure montre qu'il n'existe pas de séparation triviale entre les classes ce qui nécessite une modélisation fine.
- **Multicolinéarité :** La matrice révèle des blocs rectangulaires de couleurs homogènes, prouvant que des groupes de gènes co-varient fortement. Cette redondance d'information justifie l'utilisation de l'Elastic-Net ou du Group-Lasso pour sélectionner des groupes cohérents.

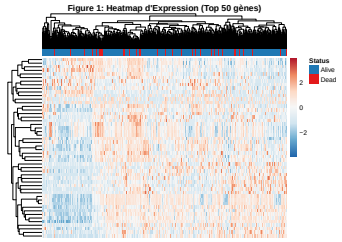


FIGURE 1 – Heatmap des 50 gènes les plus variables

4. Variable Cible (Y)

La variable cible `vital_status` est catégorielle binaire.

- **Distribution :** Nous observons un déséquilibre notable avec 1029 cas "Alive" ($\approx 83.6\%$) pour 201 cas "Dead" ($\approx 16.4\%$). Ce modèle naïf serait trompeur. Nous privilégierons des métriques comme le F1-score ou l'AUC plutôt que l'accuracy seule.

5. Lien entre X et Y

La **Figure 2** valide l'hypothèse de parcimonie (*sparsity*). La concentration massive des corrélations autour de 0 matérialise le **bruit**. Pour confirmer cela, un **test de Student** révèle que seuls **31** gènes présentent une différence d'expression statistiquement significative entre les deux groupes, imposant l'utilisation de la régularisation (Lasso) pour filtrer le bruit et sélectionner ces rares candidats pertinents.

Pour illustrer le potentiel prédictif, la **Figure 3** présente les niveaux d'expression des 4 gènes les plus significatifs (t-test, $p < 10^{-10}$). On observe une séparation nette des médianes, confirmant que le signal existe bien localement.

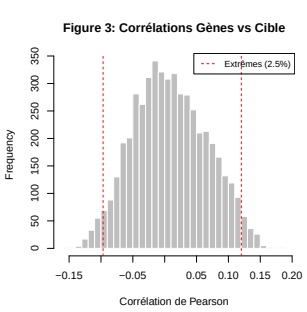


FIGURE 2 – Screening corrélations

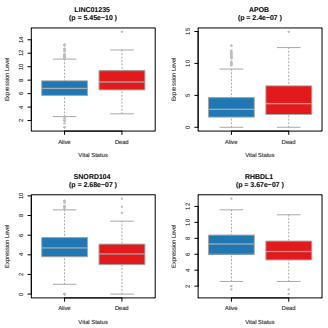


FIGURE 3 – Top 4 gènes significatifs

Dataset 2 : Clinical (Données Cliniques)

1. Présentation des Données

Ce dataset utilise des informations cliniques du TCGA pour prédire le statut vital à partir de caractéristiques médicales traditionnelles.

- **Dimensions** ($n > p$) **:** 1231 patients, 24 variables. Le contexte est favorable contrairement au dataset génomique qui a une grande dimension.
- **Types :** 5 variables numériques (âge au diagnostic, âge à l'index, durée de suivi, poids tumoral, nombre de ganglions positifs) et 19 catégorielles (stade AJCC, grade, réponse traitement, démographie).
- **Qualité :** Présence de valeurs manquantes (termes "Not Reported"/"Unknown").

2. Nature du Problème

Comme nous le savons, la variable cible est très déséquilibrée. De plus, **Figure 5** révèle une multicolinéarité entre variables temporelles (âges et durée de suivi très corrélés), justifiant l'usage de Ridge ou Elastic-Net pour stabiliser les estimations. La présence de valeurs manquantes constitue un défi quant à la stratégie d'imputation.

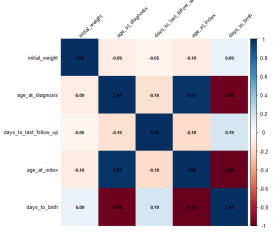


FIGURE 4 – Corrélations entre variables temporelles.

3. Variables Explicatives

Les 24 variables se divisent en deux catégories.

Numériques ($n = 5$) **:** L'âge montre une distribution bimodale (deux populations). Le temps de suivi est asymétrique. Le poids tumoral présente des valeurs extrêmes conservées car représentant des cas cliniques réels.

Catégorielles ($n = 19$) **:** Le stade AJCC est le prédicteur le plus fort, avec une séparation claire entre stades précoces (bon pronostic) et avancés (mauvais pronostic). La réponse au traitement est aussi très informative.

4. Valeurs Manquantes

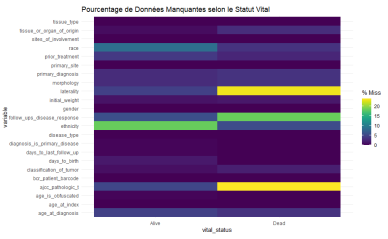


FIGURE 5 – Données manquantes selon le statut vital.

La **Figure 6** montre que les données manquantes diffèrent selon le statut vital : certaines variables sont plus souvent manquantes chez les patients décédés. Pour 4 variables critiques (ethnicité, latéralité, stade, réponse traitement), une catégorie "Missing" a été créée. Supprimer les lignes incomplètes aurait réduit l'échantillon de moitié et biaisé l'analyse. La médiane est préférée pour les variables numériques car elle est robuste aux valeurs extrêmes et préserve toutes les observations.

5. Lien entre X et Y

L'analyse statistique révèle plusieurs prédicteurs significatifs. Pour les variables numériques, le test de Student montre que les patients décédés ont des valeurs plus élevées (âge, poids tumoral). La **Figure 7** illustre ce constat : la médiane d'âge est plus haute chez les décédés. Pour les variables catégorielles, le test du Chi-deux identifie des associations fortes avec le stade AJCC.

La **Figure 8** présente l'analyse de Kaplan-Meier par stade AJCC. Les courbes montrent que les stades précoces (courbes hautes) maintiennent une probabilité de survie élevée, tandis que les stades avancés (courbes basses) diminuent rapidement. Le test du Log-Rank confirme ces différences ($p < 0.001$). Cette approche capture la dynamique pronostique plutôt qu'une classification binaire.

Cette analyse identifie les défis de chaque dataset. GeneX nécessite une sélection parcimonieuse (Lasso/Elastic-Net) face aux 5000 gènes, tandis que Clinical demande une gestion de la multicolinéarité (Ridge). Les deux approches sont complémentaires et la phase de modélisation comparera leurs performances pour déterminer si leur combinaison améliore la prédiction.

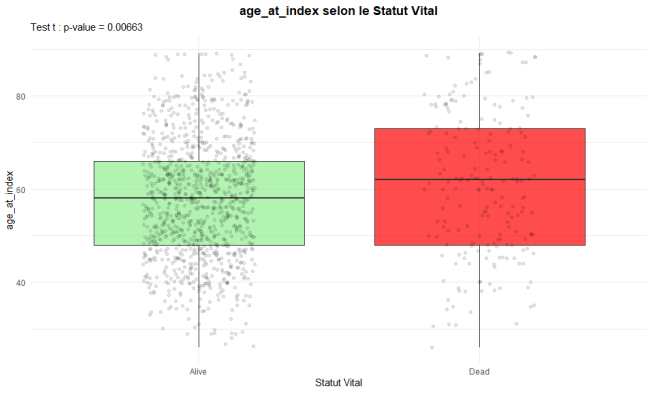


FIGURE 6 – Distribution âge vs statut vital (test de Student).

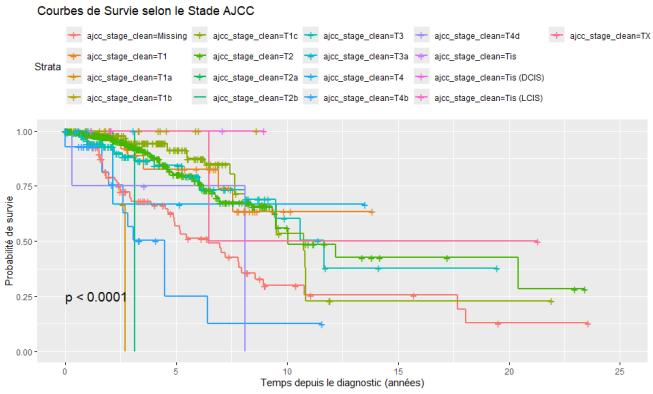


FIGURE 7 – Courbes de survie selon le stade AJCC (Kaplan-Meier).